



Кластеризация


Исаева Диана

Sber BigData Engineer




План лекции


1. Обучение без учителя
2. Задачи обучения без учителя
3. Понятие кластеризации
4. Примеры задач, которые помогает решать кластеризация
5. Меры расстояний
6. Классификация алгоритмов
7. Обзор алгоритмов

The background is black with decorative wavy orange lines in the top right and bottom left corners. The text is centered in the middle of the image.

Обучение без учителя

Обучение без учителем – это одна из задач машинного обучения, при которой системе известны только признаки множества объектов (обучающей выборки) и необходимо обнаружить взаимосвязи\закономерности между объектами множества.



The background is black with decorative wavy orange lines in the top right and bottom left corners. The lines are thin and flow in a fluid, undulating pattern.

Задачи обучения без учителя

**Обучение без
учителя**

```
graph TD; A[Обучение без учителя] --> B[Кластеризация]; A --> C[Выявление аномалий]; A --> D[Понижение размерности];
```


Кластеризация

Выявление аномалий

**Понижение
размерности**


Выявление аномалий в данных

Плохой пример выявления аномалий с помощью кластеризации




Выявление аномалий в данных


Хороший пример выявления аномалий с помощью кластеризации



Алгоритм AgglomerativeClustering
(иерархическая кластеризация)





Алгоритм DBSCAN

The background is black with decorative wavy orange lines in the top right and bottom left corners. The lines are thin and flow in a fluid, undulating pattern.

Понятие кластеризации

Кластеризация – это задача разбиения множества объектов на группы по степени их схожести между собой, которые называют кластерами.




The background is black with decorative wavy orange lines in the top right and bottom left corners. The text is centered in the middle of the slide.

Примеры задач



Анализ геоданных






Вопросы на подумать



- 1. Как определить эту самую «схожесть» объектов между собой?**
- 2. Что служит критерием, на основании которого мы будем утверждать о схожести или отличии объектов между собой?**



Меры расстояний


Евклидово расстояние

Ака Евклидова метрика

$$\rho(x, x') = \sqrt{\sum_i^n (x_i - x'_i)^2}$$

Квадрат евклидова расстояния

$$\rho(x, x') = \sum_i^n (x_i - x'_i)^2$$



Расстояние городских кварталов
aka манхэттенское расстояние
aka метрика прямоугольного города
aka метрика такси
aka расстояние Минковского


$$\rho(x, x') = \sum_i^n |x_i - x'_i|$$

Расстояние Чебышева

$$\rho(x, x') = \max(|x_i - x'_i|)$$

Степенное расстояние

$$\rho(x, x') = \sqrt[p]{\sum_i^n (x_i - x'_i)^p}$$



The background is black with decorative wavy orange lines in the top right and bottom left corners. The lines are thin and flow in a rhythmic, undulating pattern.

Классификация алгоритмов

Алгоритмы кластеризации

Иерархические

Плоские



Алгоритмы кластеризации: Плоские алгоритмы

Четкие

Нечеткие





Q&A






Обзор алгоритмов


Алгоритмы кластеризации: иерархические

Иерархические алгоритмы (также называемые алгоритмами таксономии) строят не одно разбиение выборки на непересекающиеся кластеры, а систему вложенных разбиений.




Алгоритмы кластеризации: иерархические

Восходящие




Нисходящие



Алгоритмы кластеризации: плоские

Плоские алгоритмы строят одно разбиение объектов на кластеры.



Среднеквадратическая ошибка разбиения

$$e^2(X, L) = \sum_{j=1}^K \sum_{i=1}^{n_j} \|x_i^{(j)} - c_j\|^2$$

Алгоритмы кластеризации: четкие

Четкие (или непересекающиеся) алгоритмы каждому объекту выборки ставят в соответствие номер кластера, т.е. каждый объект принадлежит только одному кластеру.


Наиболее популярный алгоритм – метод k-средних.

Алгоритмы кластеризации: нечеткие

Нечеткие (или пересекающиеся) алгоритмы каждому объекту ставят в соответствие набор вещественных значений, показывающих степень отношения объекта к кластерам.

Т.е. каждый объект относится к каждому кластеру с некоторой вероятностью.

Наиболее популярный алгоритм – алгоритм с-средних.



Метрики качества

Компактность кластеров aka Cluster Cohesion

$$WSS = \sum_{j=1}^M \sum_{i=1}^{|C_j|} (x_{ij} - \bar{x}_j)^2 \quad \Rightarrow \quad \min$$

Где M – количество кластеров

Отделимость кластеров Cluster Separation

aka

$$BSS = n \cdot \sum_{j=1}^M (\overline{x_j} - \overline{x})^2 \quad \Rightarrow \quad \max$$

Где М – количество кластеров

Силуэт aka Silhouette score

$$\text{Average}(b - a / \max(b, a)) \implies [0;1] \implies 1$$

Где:

- a - среднее внутрикластерное расстояние (среднее расстояние от точки до каждой точки внутри кластера)
- b - среднее межкластерное расстояние (среднее расстояние от точки до каждой точки ближайшего соседнего кластера)

Индекс Дэвиса-Болдуина aka Davies–Bouldin Index

$$DB(C) = \frac{1}{K} \sum_{c_k \in C} \max_{c_l \in C \setminus c_k} \left\{ \frac{S(c_k) + S(c_l)}{\|\bar{c}_k - \bar{c}_l\|} \right\}, \quad \Longrightarrow [0; \infty) \Longrightarrow \min$$

где:

$$S(c_k) = \frac{1}{|c_k|} \sum_{x_i \in c_k} \|x_i - \bar{c}_k\|$$

Индекс Calinski-Harabasz

$$CH = \left[\frac{\sum_{k=1}^K n_k \|c_k - c\|^2}{K-1} \right] / \left[\frac{\sum_{k=1}^K \sum_{i=1}^{n_k} \|d_i - c_k\|^2}{N-K} \right] \Longrightarrow [0; \infty) \Longrightarrow \max$$

Где:

- K - количество кластеров
- N - количество всех объектов
- d - объект кластеризации
- n - количество объектов в кластере k
- c - центроид кластера k

Я В СВОЕМ ПОЗНАНИИ НАСТОЛЬКО ПРЕИСПОЛНИЛСЯ,

ЧТО Я КАК БУДТО БЫ УЖЕ СТО ТРИЛЛИОНОВ МИЛЛИАРДОВ ЛЕТ ПРОЖИВАЮ НА ТРИЛЛИОНАХ И ТРИЛЛИОНАХ ТАКИХ ЖЕ ПЛАНЕТ, КАК ЭТА ЗЕМЛЯ, МНЕ ЭТОТ МИР АБСОЛЮТНО ПОНЯТЕН, И Я ЗДЕСЬ ИЩУ ТОЛЬКО ОДНОГО - ПОКОЯ, УМИРОТВОРЕНИЯ И ВОТ ЭТОЙ ГАРМОНИИ, ОТ СЛИЯНИЯ С БЕСКОНЕЧНО ВЕЧНЫМ, ОТ СОЗЕРЦАНИЯ ВЕЛИКОГО ФРАКТАЛЬНОГО ПОДОБИЯ И ОТ ВОТ ЭТОГО ЗАМЕЧАТЕЛЬНОГО ВСЕЕДИНСТВА СУЩЕСТВА, БЕСКОНЕЧНО ВЕЧНОГО, КУДА НИ ПОСМОТРИ, ХОТЬ ВГЛУБЬ – БЕСКОНЕЧНО МАЛОЕ, ХОТЬ ВВЫСЬ - БЕСКОНЕЧНОЕ БОЛЬШОЕ, ПОНИМАЕШЬ? А ТЫ МНЕ ОПЯТЬ СО СВОИМ ВОТ ЭТИМ, ИДИ СУЕТИСЬ ДАЛЬШЕ, ЭТО ТВОЁ РАСПРЕДЕЛЕНИЕ, ЭТО ТВОЙ ПУТЬ И ТВОЙ ГОРИЗОНТ ПОЗНАНИЯ И ОЩУЩЕНИЯ ТВОЕЙ ПРИРОДЫ, ОН НЕСОИЗМЕРИМО МЕЛОК ПО СРАВНЕНИЮ С МОИМ, ПОНИМАЕШЬ? Я КАК БУДТО БЫ УЖЕ ДАВНО ГЛУБОКИЙ СТАРЕЦ, БЕССМЕРТНЫЙ, НУ ИЛИ ТАМ УЖЕ ПОЧТИ БЕССМЕРТНЫЙ, КОТОРЫЙ НА ЭТОЙ ПЛАНЕТЕ ОТ ЕЁ САМОГО ЗАРОЖДЕНИЯ, ЕЩЁ КОГДА ТОЛЬКО СОЛНЦЕ ТОЛЬКО-ТОЛЬКО СФОРМИРОВАЛОСЬ КАК ЗВЕЗДА, И ВОТ ЭТО ГАЗОПЫЛЕВОЕ ОБЛАКО, ВОТ, ПОСЛЕ ВЗРЫВА, СОЛНЦА, КОГДА ОНО ВСПЫХНУЛО, КАК ЗВЕЗДА, НАЧАЛО ФОРМИРОВАТЬ ВОТ ЭТИ КОАЦЕРВАТЫ, ПЛАНЕТЫ, ПОНИМАЕШЬ, Я НА ЭТОЙ ЗЕМЛЕ УЖЕ КАК БУДТО ПОЧТИ ПЯТЬ МИЛЛИАРДОВ ЛЕТ ЖИВУ И ЗНАЮ ЕЁ ВДОЛЬ И ПОПЕРЕК ЭТОТ ВЕСЬ МИР, А ТЫ МНЕ КАКИЕ-ТО...

**алгоритмы кластеризации
втираешь**



Q&A

