

ML School by REU

Деревья и случайный лес

Решающее дерево

Бинарное дерево, где

- во внутренних вершинах заданы предикаты,
- в каждой листовой вершине задан прогноз.

Наиболее популярные предикаты

$$[x^j \leq t] \quad \text{и} \quad [x^j = t]$$

Прогноз в листе

Задача регрессии: вещественное число.

Задача классификации: класс, вероятности классов.

Параметры решающего дерева

Число вершин.

Число потомков у каждой вершины.


Предикаты.

Прогнозы в листьях.

Экзамен по ML



После экзамена по ML



Как посадить дерево?

Жадный алгоритм построения дерева

1. Поместить в корень всю выборку: $X_1 = X$.
2. Начать построение с корня: $m = 1$.
3. Если выполнен **критерий останова** для вершины m , то считаем **прогноз** и выход.
4. Найти **лучшее разбиение** $[x_j \leq t]$ для вершины m .
5. Разбить вершину m на дочерние вершины l и r .
6. Повторить шаги 3-6 для дочерних вершин l и r .


Как правильно посадить дерево

✓ Правильно

✗ Корни
не расправлены
и загнуты вверх



✗ Слишком
высокая посадка,
корни оголены

✗ Полностью
заглублена
корневая шейка



Как посадить дерево?

- Жадное построение
- Растим дерево от корня к листьям




Как сравнить разбиения?


- **Энтропия** – мера неопределенности распределения.
- Дискретное распределение:

$$H(p_1, \dots, p_n) = - \sum_{i=1}^n p_i \log p_i$$



$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$



Высокая энтропия



Низкая энтропия



*Считаем, что $0 \ln(0) = 0$

Как сравнить разбиения?

- Выдаём в вершине распределение классов $c = (c_1, \dots, c_k)$.
- Качество такого распределения можно измерить с помощью критерия Бриера:



$$H(R) = \min_{\sum_k c_k = 1} \frac{1}{|R|} \sum_{(x_i, y_i) \in R} \sum_{k=1}^K (c_k - [y_i = k])^2$$

- Оптимум – доли классов: $c^* = (p_1, \dots, p_k)$:


$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$

- При подстановке c^* в исходный $H(R)$ получим **критерий Джини**:

$$H(R) = \sum_{k=1}^K p_k(1 - p_k)$$



Как сравнить разбиения?




Поиск разбиения

- Выбор лучшего предиката в вершине

Пусть в вершине m оказалась выборка X_m . $Q(X_m, j, t)$ – критерий качества условия $[x_j \leq t]$.
Ищем лучшие параметры j и t перебором:

$$Q(X_m, j, t) \rightarrow \max(j, t)$$

$$Q(X_m, j, t) = H(X_m) - \frac{|X_l|}{|X_m|} H(X_l) - \frac{|X_r|}{|X_m|} H(X_r)$$



Критерии информативности

- $H(X)$. Зависит от ответов на выборке X . Чем меньше разброс ответов, тем меньше значение $H(X)$.

Регрессия

Дисперсия

$$H(R) = \frac{1}{|R|} \sum_{(x_i, y_i) \in R} \left(y_i - \frac{1}{|R|} \sum_{(x_j, y_j) \in R} y_j \right)^2$$

Классификация

Энтропия

$$H(R) = - \sum_{k=1}^K p_k \log p_k$$

Критерий Джини

$$H(R) = \sum_{k=1}^K p_k (1 - p_k)$$

$$p_k = \frac{1}{|X|} \sum_{i \in X} [y_i = k]$$

Поиск разбиения

- После того, как разбиение найдено, разбиваем X_m на 2 подвыборки.

$$X_l = \{x \in X_m \mid [x^j \leq t]\}$$

$$X_r = \{x \in X_m \mid [x^j > t]\}$$

- Повторяем для X_l и X_r .

Критерии останова

- Ограничение максимальной глубины дерева.
- Ограничение минимального числа объектов в листе.
- Ограничение максимального числа листьев в дереве.
- Если ошибка константного прогноза в вершине менее задаваемого порога.
- В вершине все объекты одного класса.

Прогноз в листе

Регрессия

- Оптимальный прогноз с точки зрения оптимизируемого функционала.


$$a_m = \frac{1}{|X_m|} \sum_{i \in X_m} y_i$$

Классификация


- Вероятности классов.
- Наиболее популярный класс.

$$a_m = \arg \max_{y \in \mathbb{Y}} \sum_{i \in X_m} [y_i = y]$$

Обучение деревьев





- Восстанавливают сложные нелинейные закономерности.
- Могут построить сколь угодно сложную поверхность. Для этого увеличивают глубину.
- Склонны к переобучению.




Переобучение деревьев


- Дерево может достичь нулевой ошибки на любой выборке. Такое дерево, скорее всего, переобучено.
- Pruning (стрижка) для борьбы с переобучением.
- Неустойчивость деревьев.



Глубина дерева = 2



Глубина дерева = 5



Резюме

1. Решающее дерево – мощная модель.
2. Обучение эвристическое.
3. Много тонкостей с переобучением.
4. Обычно используется в композициях.

Композиции алгоритмов

N базовых алгоритмов $b_1(x), \dots, b_n(x)$.

Композиция


- Усреднение наблюдений

$$a(x) = \frac{1}{N} \sum_{n=1}^N b_n(x)$$


- majority vote

$$a(x) = \arg \max_{y \in \mathbb{Y}} \sum_{n=1}^N [b_n(x) = y]$$

Bagging (Bootstrap aggregation)



Boosting



Bias-variance decomposition

- Шум - как сильно ошибается оптимальная модель.
- Смещение - как сильно в среднем отклоняется модель (конкретного метода обучения) от оптимальной модели.
- Разброс - как сильно меняется модель при изменении обучающей выборки (устойчивость модели).

$$L(\mu) = \underbrace{\mathbb{E}_{x,y} \left[(y - \mathbb{E}[y | x])^2 \right]}_{\text{шум}} +$$
$$+ \underbrace{\mathbb{E}_x \left[(\mathbb{E}_X [\mu(X)] - \mathbb{E}[y | x])^2 \right]}_{\text{смещение}} + \underbrace{\mathbb{E}_x \left[\mathbb{E}_X \left[(\mu(X) - \mathbb{E}_X [\mu(X)])^2 \right] \right]}_{\text{разброс}}$$

Композиции алгоритмов

Как по одной выборке обучить N разных моделей?

Bootstrap

- Выбираем из обучающей выборки I объектов с возвращением.
- $\sim \frac{2}{3}$ I различных объектов в каждой подвыборке.

Bagging (Bootstrap Aggregating)

- Базовые алгоритмы обучаются независимо на своём подмножестве данных.
- Ответы базовых алгоритмов усредняются или выбор ответа по большинству.

Метод случайных подпространств

- Выбор лучшего предиката в конкретной вершине основан на случайном подмножестве признаков.

Смещение композиции, обученной с помощью бэггинга

$$\begin{aligned}\mathbb{E}_{x,y} \left[\left(\mathbb{E}_X \left[\frac{1}{N} \sum_{n=1}^N \tilde{\mu}(X)(x) \right] - \mathbb{E}[y | x] \right)^2 \right] &= \\ &= \mathbb{E}_{x,y} \left[\left(\frac{1}{N} \sum_{n=1}^N \mathbb{E}_X [\tilde{\mu}(X)(x)] - \mathbb{E}[y | x] \right)^2 \right] = \\ &= \mathbb{E}_{x,y} \left[\left(\mathbb{E}_X [\tilde{\mu}(X)(x)] - \mathbb{E}[y | x] \right)^2 \right].\end{aligned}$$


Дисперсия композиции, обученной с помощью бэггинга

$$\begin{aligned}\mathbb{E}_{x,y} \left[\mathbb{E}_X \left[\left(\frac{1}{N} \sum_{n=1}^N \tilde{\mu}(X)(x) - \mathbb{E}_X \left[\frac{1}{N} \sum_{n=1}^N \tilde{\mu}(X)(x) \right] \right)^2 \right] \right] &= \\ &= \frac{1}{N} \mathbb{E}_{x,y} \left[\mathbb{E}_X \left[\left(\tilde{\mu}(X)(x) - \mathbb{E}_X [\tilde{\mu}(X)(x)] \right)^2 \right] \right] + \\ &+ \frac{N(N-1)}{N^2} \mathbb{E}_{x,y} \left[\mathbb{E}_X \left[\left(\tilde{\mu}(X)(x) - \mathbb{E}_X [\tilde{\mu}(X)(x)] \right) \times \right. \right. \\ &\quad \left. \left. \times \left(\tilde{\mu}(X)(x) - \mathbb{E}_X [\tilde{\mu}(X)(x)] \right) \right] \right]\end{aligned}$$

Случайный лес


Для $n=1, \dots, N$:

1. Генерируем подвыборку из X с помощью **бутстрапа**.
2. Строим решающее дерево $bn(x)$ на данной подвыборке.
3. Дерево строится, пока в каждом листе не окажется более n_min объектов. Базовые деревья **глубокие**.
4. Оптимальное разбиение ищется среди q случайных признаков (**метод случайных подпространств**). Выбираются заново при каждом разбиении!



Резюме

1. Универсальный метод машинного обучения.
2. Не переобучается при росте числа базовых алгоритмов.
3. Долгое обучение.
4. Если дерево имеет высокое смещение, то бэггинг не даст хороший результат.



Спасибо за внимание!

Васильева Наталья
nvasileva.1609@gmail.com
tg: +79035249776